

Évaluation de l'impact environnemental de la plateforme d'IA générative de la DGFIP

Letizia Gaggiotti, Margot Martin, Campbell Powers, Anne Thébaud



CADRE GÉNÉRAL

- Évaluer les impacts directs et indirects de l'IA via une revue de la littérature pour toutes les étapes du cycle de vie.
- **Analyse du Cycle de Vie (ACV)** pour aller au-delà de la simple consommation électrique opérationnelle.
(Berthelot et al., 2024; Plociennik et al., 2025; Ciambrone 1997)



(Luccioni et al., 2023)

- **Indicateur clé : Équivalent CO2**

CADRE GÉNÉRAL


- **Répartition des émissions (Scopes) :** (Luccioni, Viguier, and Ligozat 2023)
 - **Émissions sur site (2%) :** Groupes électrogènes diesel, fuites de gaz réfrigérants.
 - **Émissions d'énergie directes (~70%) :** Consommation des serveurs locaux lors de l'inférence.
 - **Émissions incorporées (20% à 30%) :** Fabrication, transport, fin de vie du matériel et dette carbone liée à l'entraînement initial.
- => Cette répartition dépend du mix énergétique, de la taille des modèles, de l'hardware utilisé, ...**

PHASE I: HARDWARE ET INFRASTRUCTURE

- **Périmètre** : Évaluation “du berceau à la sortie d'usine” (Cradle-to-Gate).
- Répartition de l'empreinte matérielle :
 - **Composants (Mémoire, circuits intégrés)** : 91%.
 - **Assemblage et transport** : 9%
- **Baseline**: Une HGX baseboard (8 GPUs) = 1,312 kg CO₂e
- **Parc de la DGFIP (24 GPUs / 3 baseboards)**: 3,936 kg CO₂e (3.9t)
- **Equivalences**:
 - **18,000 km** en voiture thermique
 - Fabrication de 15 ordinateurs (sans les écrans).

(ADEME, impact CO₂ equivalent calculator (2025))

HGX H100 PCF: Material Breakdown by Component Type
(Kg CO₂e/Unit) *A unit corresponds to 8 GPUs*



(NVIDIA's study of the carbon footprint of their HGX H100 80GB HBM3 GPU)

Point clé : les GPU ne représentent qu'une part relativement faible des émissions totales sur l'ensemble du cycle de vie, surtout si l'on répartit ces émissions sur une période d'utilisation de quatre ans.

PHASE I: HARDWARE ET INFRASTRUCTURE

- **Consommation d'eau** : Plus de 30 000 litres pour fabriquer un seul GPU avancé.
- **PUE (Efficacité énergétique)** :
 - **PUE actuel DGFIP** : 1.7 (Pour 1 kWh utile, 0.7 kWh est gaspillé pour le refroidissement/éclairage).
 - **Cible** : 1.4 PUE.
- **Autres émissions** :
 - **Fuites de gaz** : R-134a (Potentiel de réchauffement 1 430x supérieur au CO2).
 - Générateurs diesel qui émettent du CO2 pendant les tests mensuels et lors des pannes de courant

PHASE I: HARDWARE ET INFRASTRUCTURE

Recommandations pour la DGFIP

- **Longévité du matériel** : conserver les cartes graphiques afin d'optimiser l'amortissement des émissions liées à leur fabrication.
- **Remplacement du matériel** : lorsque le matériel doit être remplacé, privilégier l'efficacité énergétique (par exemple, les puces NVIDIA B200 offrent un rapport énergie/jeton nettement supérieur).
- **Refroidissement** : passer à des systèmes de refroidissement par eau. Cela permet de réduire le PUE à environ 1,1, ce qui diminue l'empreinte opérationnelle de 30 %.

PHASE II: ENTRAÎNEMENT INITIAL

Même en tant qu'utilisateur en aval, la DGFIP hérite du coût environnemental de chaque modèle qu'elle déploie.

Il est impossible de déterminer avec précision la part de responsabilité de chacun :

- Le volume total d'inférences pour chaque modèle étant inconnu, la DGFIP ne peut pas calculer sa part exacte de sa « dette carbone ».

La DGFIP devrait se baser sur les émissions totales liées à la formation initiale pour évaluer et sélectionner les modèles. **Problème** : 99 % des modèles sur Hugging Face ne communiquent pas de données sur leurs émissions. (Castaño et al. 2023)

Model	Size	Location	Data Quality	Estimation tCO ₂ e
Llama-3.3-70B	70B	US	Reported	2040
GPT-OSS-120B	120B	US	Partial	≈ 1087
GPT-OSS-20B	21B	US	Partial	≈ 108,7
Qwen2.5-Coder-32B	32B	China	Partial	≈ 466,4
Mistral-Small-24B	24B	France/US	Unknown	—
Whisper-Large-v3	809M	Mixed	Unknown	—
gte-Qwen2-1.5B	1.5B	China	Unknown	—
dgfip-e5-large	335M	France	Unknown	—

PHASE II: ENTRAÎNEMENT INITIAL

Context Reporting


The screenshot shows the 'ML CO2 Impact' web application. At the top, there's a navigation bar with links: Compute, Publish, Learn, Act, and About. Below the navigation bar, there's a form with four input fields: 'Hardware type' (set to H100 SXM), 'Hours Used' (set to 2100000), 'Provider' (set to Azure), and 'Region of Compute' (set to Central US). A red 'COMPUTE' button is positioned below these fields. Below the button, a white box displays the results: 'CARBON EMITTED' as 1087800 and 'CARBON ALREADY OFFSET BY PROVIDER' as 1087800, both in kg CO₂ eq. A 'PUBLISH THIS!' button is next to the offset value. A small red question mark icon is next to the unit 'kg CO₂ eq.'.

(Machine Learning CO2 Impact Calculator, Green Algorithms Calculator)

Unknown emissions

Indicateurs de substitution (Proxys) :

- Volume du jeu de données / Heures d'entraînement.
- Matériel utilisé et PUE.
- Localisation géographique de l'entraînement.
- Taille du modèle.



(Ariyanti et al. 2025)

PHASE II: ENTRAÎNEMENT INITIAL

Recommandations pour la DGFIP


- **Privilégiez les modèles accompagnés de fiches techniques** publiées et de rapports sur les émissions de carbone.
 - En l'absence de données contextuelles, utilisez **des outils tels que ML CO2 Impact ou Green Algorithms pour estimer les émissions.**
 - En l'absence de données contextuelles, utilisez des indicateurs de substitution, proxys (taille de l'ensemble de données, matériel, lieu de l'entraînement).
 - Privilégiez les modèles **de petite taille.**
- => Une empreinte carbone plus élevée lors de l'entraînement implique généralement des coûts d'inférence plus élevés**

PHASE III: INFÉRENCE

Outil de mesure des émissions de CO2 de l'inférence

- **Émissions de CO₂ liées à l'inférence** : consommation d'énergie (W) × PUE × mix électrique => l'outil présentera en détail la méthodologie permettant de calculer les émissions de CO₂ de l'inférence à partir des modèles de la DGFIP
- **Émissions de CO₂ en mode veille (suspension)** : les serveurs consomment encore 10 % de leur puissance maximale. Un GPU NVIDIA H100 consomme entre 50 et 60 W à 0 % d'utilisation. Pour un cluster de 24 GPU, cela représente une consommation de 1,2 à 1,4 kW, 24 heures sur 24, 7 jours sur 7.
(NVIDIA carbon footprint of their HGX H100 GPU)


- **Ce que vous nous avez demandé de faire :**



PHASE III: INFÉRENCE


Statistiques descriptives : étendue des données

- **Couverture des données dont nous disposons** : seulement 17 jours de recoupement entre les données énergétiques et les données de consommation




PHASE III: INFÉRENCE

Statistiques descriptives : Données d'usage (logs)



PHASE III: INFÉRENCE


Statistiques descriptives : Données d'usage (logs)



PHASE III: INFÉRENCE


Statistiques descriptives : Données d'énergie

Extrait de la consommation électrique hebdomadaire, relevée toutes les 5 minutes, pour une partie des 17 jours fournis



PHASE III: INFÉRENCE

Statistiques descriptives : Données d'énergie



OUTIL D'ÉVALUATION

La méthodologie

Étape 1 : Mesurer l'énergie totale

- Les compteurs de puissance (PDU) sur les serveurs GPU enregistrent l'énergie chaque minute.
- Nous additionnons toutes les lectures du mois, puis appliquons un facteur PUE de 1,7.

Étape 2 : Attribuer l'énergie par modèle

- Nous avons calculé la part de consommation d'énergie de chaque modèle en fonction des jetons (tokens) traités et de la taille du modèle, en appliquant trois corrections:
 - **Quantification (Quantisation)** : Les modèles FP8 utilisent environ 50 % de calcul en moins que les équivalents BF16.
 - **Architecture MoE** : Les modèles gptoss n'activent qu'une petite fraction des paramètres par requête.
 - **Puissance au repos (Idle power)** : Estimation d'environ 7 % de la consommation d'énergie par le GPU simplement pour rester allumé, quel que soit l'usage.

OUTIL D'ÉVALUATION

Attribution corrections applied to the energy model

1. Numerical precision (q_i)

Lower precision = fewer FLOPs per token:

Format	q_i	Models
BF16 / FP16	1.00	Llama, qwen3vl, Whisper, gte
FP8	0.50	Qwen-Coder, Mistral
MXFP4-MoE	0.34	gptoss120b, gptoss20b

2. Mixture-of-Experts (MoE)

Only a few experts fire per token -- effective compute << total parameters:

Model	Total params	Active params	Architecture
gptoss120b	120B	15B	128 experts, top-4
gptoss20b	22B	5B	32 experts, top-4

3. GPU idle power

A100 GPUs stay in high-power state (P0) even with no active requests (~50 W idle).

7% of cluster energy is allocated by hosting time (d_i), not by token volume.


$$s_i = 0.93 \cdot \frac{w_i}{\sum_j w_j} + 0.07 \cdot \frac{d_i}{\sum_j d_j}$$

OUTIL D'ÉVALUATION

Février 2026 résultats


Energy distribution -- central scenario | 1--24 Feb 2026 | facility energy (kWh, PUE = 1.7)

A Facility energy share per model



Model	
Llama-3-3-70B-128k	59.6%
qwen3vl32binstruct	27.9%
gptoss120b	5.5%
gte-Qwen2-1-5B	2.7%
gptoss20b	2.4%
deepdml-Whisper-v3	1.8%

B Facility energy breakdown



Total facility energy	8,780 kWh
Total CO ₂	457 kg CO ₂ e
Equiv. car distance	≈ 3,805 km

OUTIL D'ÉVALUATION

Février 2026 résultats

Results per model -- 1--24 Feb 2026 (facility: 8,780 kWh | CO₂: 457 kg | PUE=1.7 | 0.052 kg/kWh)

Model	Share	kWh	CO ₂ (kg)	kWh/Mtok	Wh/req	gCO ₂ /req
Llama-3-3-70B-128k	60%	5,233	272	16.91	4.82	0.251
qwen3vl32binstruct	28%	2,447	127	7.91	2.25	0.117
gptoss120b	6%	484	25	1.57	0.45	0.023
gte-Qwen2-1-5B	3%	240	13	0.78	0.21	0.011
gptoss20b	2%	214	11	0.69	0.20	0.010
deepdml-Whisper-v3	2%	160	8	0.52	0.15	0.008
Total	100%	8,780	457	4.73	1.34	0.070

OUTIL D'ÉVALUATION

Limitations

Hypothèses et limites

- Déploiement/désinstallation par modèle
- Quel GPU héberge quel modèle ?
- Consommation électrique par GPU utilisé
- Consommation électrique calculée à partir d'un instantané de 80 minutes
- Pas de données pour janvier 2026

Recommandations pour la DGFIP

- **Mettre en place une surveillance au niveau des GPU** : nvidia-smi :
Interface de gestion du système :
 - **Consommation électrique par GPU** et non par PDU pour le rack
 - **Utilisation de la mémoire** : gestion du déploiement des modèles
- **Distinguer les jetons d'entrée et de sortie**

OUTIL DE SUIVI DE LA CONSOMMATION ÉNERGÉTIQUE

- Afin de pallier les limites des estimations, nous avons développé un outil de suivi permettant à votre équipe de surveiller l'intensité énergétique de chaque modèle que vous déployez.
- Cet outil a pour objectif de permettre à votre équipe d'automatiser la collecte, l'analyse et l'intégration des données énergétiques des modèles dans votre processus de sélection des modèles.
- Bien que l'outil fournisse actuellement des données énergétiques sur les modèles, il nécessite des développements de votre part pour affiner l'agrégation des données, le configurer en fonction de vos sources de données internes et l'étendre à tous les modèles que vous déployez actuellement.

OUTIL DE SUIVI DE LA CONSOMMATION ÉNERGÉTIQUE

- En s'appuyant sur les données énergétiques et de déploiement des modèles du mois de février, l'outil collecte et organise automatiquement les chiffres d'utilisation et de déploiement pour chaque modèle. Notre objectif est de **mesurer la consommation en Wh pour 1 000 requêtes**, la norme du secteur, pour chaque modèle déployé.
- Les données énergétiques fournissent des **données cumulées en Wh par intervalle de cinq minutes par voie**. Les données d'utilisation des modèles indiquent **le nombre de jetons par jour**, en regroupant tous les modèles utilisés au cours d'une même journée sous un même total de jetons.
- Les deux premiers jours de février n'ayant vu qu'un seul modèle en fonctionnement, nous sommes en mesure **d'isoler les données d'énergie et d'utilisation pour le modèle Qwen 2 Instruct**. Il ne s'agit pas de fournir une estimation fiable, mais plutôt de développer l'algorithme que votre équipe pourra exécuter de son côté afin de capturer rapidement des estimations d'énergie pour tous vos modèles.

Next GTE Qwen 5B Instruct:

- **878.30 Wh / 1000 jetons (tokens)**
- **30.07 gCO₂e / 1000 jetons (8.31 kgCO₂e totale)**
- **138 mètres en voiture thermique / 1000 jetons**

LIMITES DE NOTRE OUTIL

1 Cadrage temporel

Nous extrayons actuellement l'intensité énergétique du réseau électrique français par intervalles de quinze minutes (le plus court proposé). Toutefois, si vous décidez de déployer des modèles en dehors de la France, cet algorithme sous-estimera les émissions de carbone. Nous optons pour des données en temps réel plutôt qu'historiques, de sorte que les données RTE ne couvrent que les 1,5 derniers mois.

2 Précision des estimations

L'énergie consommée par le serveur au repos (idle energy) peut représenter jusqu'à 10 % de l'énergie totale de tous les modèles. Cependant, nous ne disposons pas de données révélant les temps d'arrêt des serveurs (server downtime). Capturer ces informations permettrait de corriger la surestimation de la consommation d'énergie et des émissions de carbone.

3 Précision des données

Des données au niveau du modèle et au niveau intra-journalier sont nécessaires pour les données de jetons (tokens) et de requêtes. Actuellement, les mesures ne nous permettent pas de capturer la dispersion entre les modèles ou au sein d'un même modèle, excepté pour un modèle sur deux jours.

4 Caractéristiques des modèles

Nous vous encourageons à utiliser l'API HuggingFace pour comparer les caractéristiques des modèles en vue de futurs déploiements. Cela inclut des tests ex-post avant le déploiement en production et potentiellement une estimation ex-ante pour minimiser l'empreinte énergétique.

OUTIL DE SUIVI DE LA CONSOMMATION ÉNERGÉTIQUE

Recommandations pour la DGFIP

- Il n'existe donc pas de répartition de l'utilisation des modèles à exploiter pour estimer l'utilisation par modèle. Des données désagrégées sont nécessaires :
 - **Nombre total de jetons par modèle et par période**
 - **Durées d'exécution des modèles**, de préférence à la minute près. Cela permettra de déterminer quand le serveur est inactif.
- De plus, les données relatives au GPU sur lequel un modèle est exécuté amélioreront la fiabilité de l'estimation de la consommation énergétique du modèle

PHASE IV: GESTION DE LA FIN DE VIE

- **Le manque de données** : Absence de métriques de déchets électroniques spécifiques à l'IA (OECD 2024)
- **Le paradoxe de l'obsolescence dû aux gains rapides** : L'efficacité (gCO2e/Exaflop) s'améliore si vite qu'elle incite à un remplacement prématuré du matériel avant son amortissement.
 - **Amortissement des serveurs classiques** : 5 à 7 ans.
 - **Amortissement des GPU haute performance (pour l'IA)** : 3 ans.
- **Démantèlement / Transport** : Empreinte logistique élevée dépendant du matériel spécifique.
(Wang et al., “Computational waste from generative AI” (2024))
- **Recyclage en boucle fermée** : Potentiel de compensation de 4 % de l'empreinte carbone de fabrication
(Schneider et al., “LCA of AI hardware” (2025))

PHASE IV: GESTION DE LA FIN DE VIE

Recommandations pour la DGFIP

- **Prolonger la durée de vie du GPU** d'un an
- **Collaborer avec Dell** sur une méthodologie de recyclage conforme aux normes du secteur
- **NumEcoEval** : développé par le CGDD pour quantifier l'empreinte environnementale de chaque composant matériel et service numérique au sein de l'organisation

(<https://lesbases.anct.gouv.fr/ressources/numecoeval-calculer-l-empreinte-environnementale-de-son-systeme-d-information>)

CONCLUSION

- **Matériel et infrastructure** : Prolonger la durée de vie des GPU et améliorer l'efficacité des centres de données (refroidissement PUE).
- **Entraînement initial des modèles** : Donner la priorité aux modèles disposant d'un reporting environnemental transparent. Examiner les indicateurs clés de l'impact environnemental (taille du modèle, lieu d'entraînement, volume du jeu de données, matériel utilisé).
- **Inférence** : Utiliser l'outil d'évaluation développé pour estimer les émissions liées à l'inférence et comparer les modèles. Améliorer la granularité des données et déployer une surveillance au niveau du GPU pour affiner les estimations.
- **Fin de vie** : Étendre la durée de vie du matériel et intégrer des stratégies de recyclage.

Nous avons créé un **répertoire Github** qui centralise tous les supports de ce projet (version anglaise et française):


- **Rapport complet** détaillant chaque étape de l'évaluation du cycle de vie de l'IA (revue de la littérature et méthodologie de l'outil).
- **Code source** pour les deux outils.

CONCLUSION

D'autres manières de choisir vos modèles à l'avenir

- **Ecologit Carbon** est un outil open source permettant d'estimer la consommation d'énergie et l'empreinte environnementale liée à l'utilisation de modèles d'IA générative : (<https://huggingface.co/spaces/genai-impact/ecologits-calculator>)
- **AI energy score** : une initiative visant à établir des classements comparables en matière d'efficacité énergétique pour les modèles d'IA. Ils utilisent les mêmes puces que la DGFIP (GPU H100), ce qui est idéal pour effectuer des comparaisons entre différents types de modèles.

(<https://huggingface.co/spaces/AIEnergyScore/Leaderboard>)



Expert mode

Configure the model

Provider: OpenAI (dropdown) | Model: chatgpt 4o (dropdown)

Active parameters (B): 88 (- +) | Total parameters (B): 440 (- +) | Average TPS: 80,00 (- +)

Configure the prompt

Example prompt: Write a Tweet (50 output tokens) (dropdown) | Output completion tokens: 50 (- +)

Configure the data center

Data center PUE: 1,20 (- +) | Data center WUE [L / kWh]: 0,60 (- +) | Data center location: World (dropdown)

GHG emissions [kgCO2eq / kWh]: 0,473010 (- +) | Abiotic resources [kgSbeq / kWh]: 0,0000000134900 (- +) | Primary energy [MJ / kWh]: 2,587 (- +) | Water consumption [L / kWh]: 3,908 (- +)

Évaluation de l'impact environnemental de la plateforme d'IA générative de la DGFIP

Letizia Gaggiotti, Margot Martin, Campbell Powers, Anne Thébaud




RÉFÉRENCES

La liste complète de nos références se trouve dans notre rapport

- Berthelot, Adrien, Eddy Caron, Mathilde Jay, and Laurent Lefèvre. 2024. **“Estimating the Environmental Impact of Generative-AI Services Using an LCA-Based Methodology.”** Procedia CIRP 122: 707–712.
- Ciambrone, David F. **Environmental Life Cycle Analysis.** 1st ed. Boca Raton, FL: CRC Press, 1997.
- Eilam, Tamar, Pedro D. Bello-Maldonado, Bishwaranjan Bhattacharjee, Carlos Costa, Eun K. Lee, and Asser Tantawi. **Towards a Methodology and Framework for AI Sustainability Metrics.** IBM T. J. Watson Research Center, Yorktown Heights, USA.
- Mistral AI, **“Our Contribution to a Global Environmental Standard for AI,”** July 22, 2025
- Ligozat A.-L., Lefevre J., Bugeau A. & Combaz J. 2022. **Unraveling the hidden environmental impacts of AI solutions for environment life cycle assessment of AI solutions.** Sustainability, 14(9):5172, DOI: 10.3390/su14095172
- Luccioni A.S., Viguier S. & Ligozat A.L. 2023. **Estimating the carbon footprint of BLOOM, a 176B parameter language model.** Journal of Machine Learning Research, 24(253):1–15, <https://jmlr.org/papers/v24/23-0069.html>
- Ludvigsen, Kasper Groes Albin. **“Carbon Footprint of LLM Fine Tuning — A Case Study.”** Towards Data Science, Medium, February 22, 2024._
- Nestor Maslej et al., Artificial Intelligence Index Report 2025, arXiv preprint arXiv:2504.07139v3 (2025), <https://doi.org/10.48550/arXiv.2504.07139>
- OECD. **Measuring the Environmental Impacts of Artificial Intelligence Compute and Applications: The AI Footprint.** OECD Digital Economy Papers, No. 341. Paris: OECD Publishing, November 2022.
- Plociennik, Christiane, Ponnapat Watjanatepin, Karel Van Acker, and Martin Ruskowski. 2025. **“Life Cycle Assessment of Artificial Intelligence Applications: Research Gaps and Opportunities.”** Procedia CIRP 135: 924–929.
- Touvron, Hugo, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, et al. 2023. **“Llama 2: Open Foundation and Fine-Tuned Chat Models.”** arXiv preprint arXiv:2307.09288v2.


Annexes

Consommation électrique journalière sur l'ensemble des jours disponibles



Annexes

Consommation électrique par jour par voie



Consommation électrique moyenne par voie

