

Évaluation de l'impact environnemental de la plateforme d'IA générative de la DGFîP

Letizia Gaggiotti, Margot Martin, Campbell Powers, Anne Thébaud



L'objectif de ce rapport est de fournir une **Analyse du Cycle de Vie (ACV)** de l'infrastructure d'IA de la DGFîP. Nous allons au-delà des seules émissions de carbone liées à l'inférence en évaluant chaque étape de la chaîne de valeur de l'IA : des matières premières nécessaires à la fabrication des GPU à l'énergie opérationnelle des inférences quotidiennes, jusqu'à la gestion finale des déchets matériels.

Nous avons également créé un **Outil d'Attribution Énergétique** développé pour combler le manque de granularité dans les données énergétiques. Alors que les compteurs PDU standard ne fournissent qu'une consommation agrégée, notre outil utilise une logique de pondération multifactorielle intégrant la précision numérique (quantisation), le nombre de paramètres actifs (MoE) et la consommation au repos des GPU pour isoler l'empreinte carbone de chaque modèle spécifique. Cela pourrait aider la DGFîP dans la sélection de ses modèles sur la base des émissions de CO_2 par requête.

Table des matières


1	Cadre général	3
1.1	Analyse du Cycle de Vie Environnemental (ACV)	3
1.2	Répartition des émissions par périmètre (scopes)	3
2	Phase I : Matériel et infrastructure	4
2.1	Description de l'infrastructure et des modèles à la DGFîP	4
2.2	Empreinte environnementale des puces H100	4
2.3	Efficacité du centre de données	5
3	Phase II : Entraînement initial	7
3.1	Cadre général pour comprendre la responsabilité de la DGFîP	7
3.2	Émissions de l'entraînement initial des modèles pré-entraînés utilisés par la DGFîP	7
3.2.1	Efficacité énergétique certifiée	8
3.2.2	Sensibilisation à l'énergie (Energy awareness)	8
3.2.3	Reporting de base des émissions	8
3.2.4	Reporting du contexte	8

3.2.5	Émissions et contexte inconnus	9
3.3	Tableau des modèles de la DGFIP	10
4	Phase II Bis : Fine-Tuning (Affinage)	10
5	Phase III : Inférence	12
5.1	Développement de l'outil d'évaluation de l'inférence	12
5.2	Méthodologie et facteurs d'efficacité	12
6	Phase IV : Gestion de la fin de vie	14
7	Méthodologie de l'outil	15
7.1	Aperçu et sources de données	15
7.2	Mesure de l'énergie	15
7.3	Attribution par modèle	16
7.4	Énergie finale et CO ₂ par modèle	18
7.5	Résultats de février 2026	18
7.6	Limites et incertitudes connues	18
8	Conclusion	20
8.1	Conclusion sur l'ensemble de l'ACV	20
8.2	Recommandations finales et extensions	20

Cadre général

1.1 Analyse du Cycle de Vie Environnemental (ACV)

Pour évaluer l’empreinte environnementale de la plateforme DGF_iP, nous avons mené une revue de la littérature couvrant les émissions directes et indirectes à toutes les étapes du cycle de vie de l’IA, en suivant les méthodologies établies par la recherche récente (BERTHELOT et al. 2024 ; PLOCIENNIK et al. 2025 ; CIAMBRONE 2018). Nous nous sommes concentrés sur les émissions de CO_2 , mais d’autres sorties peuvent être prises en compte, telles que la consommation de matériaux (y compris les terres rares) et la consommation d’eau (LUCCIONI, VIGUIER et LIGOZAT 2023).



1.2 Répartition des émissions par périmètre (scopes)

La charge environnementale n’est pas uniformément répartie. Sur la base de l’analyse du cycle de vie des modèles à grande échelle (LUCCIONI, VIGUIER et LIGOZAT 2023), nous classons les émissions en trois segments distincts :

- **Émissions sur site (< 2%)** : Il s’agit des émissions de CO_2 du centre de données lui-même. Celles-ci incluent des émissions telles que les fuites de gaz réfrigérants dans les systèmes de refroidissement et la mise en route des générateurs de secours diesel.
- **Émissions d’énergie directe (70%)** : Cela représente la part dominante, principalement tirée par la consommation d’électricité des serveurs locaux pendant la phase d’inférence, lorsque la plateforme est opérationnelle.
- **Émissions incorporées (20% à 30%)** : Celles-ci proviennent de la chaîne de valeur, englobant la fabrication, le transport et le traitement de fin de vie du matériel. Ce périmètre inclut également une fraction amortie de la dette carbone initiale de l’entraînement, c’est-à-dire le coût environnemental lors de l’entraînement du modèle (LUCCIONI, VIGUIER et LIGOZAT 2023).

Ces pourcentages ne sont pas statiques ; ils fluctuent considérablement en fonction de l’intensité carbone du réseau électrique, de l’architecture spécifique du matériel (par exemple, TPU vs GPU) et de la taille des paramètres des modèles utilisés.

Ce rapport est structuré en quatre phases principales :

- **Phase I** : Matériel et infrastructure
- **Phase II** : Entraînement
- **Phase III** : Inférence
- **Phase IV** : Fin de vie

Phase I : Matériel et infrastructure

La première phase de notre analyse se concentre sur la couche physique (hardware) de la plateforme et le détail des émissions de CO₂ liées à l'infrastructure du centre de données.

2.1 Description de l'infrastructure et des modèles à la DGFIP

L'infrastructure est caractérisée par des GPU répartis dans deux environnements :

- **Environnement de production** : 8 serveurs, chacun équipé de 4 GPU, totalisant **32 GPU**.
- **Environnement de développement** : 2 serveurs, chacun équipé de 4 GPU, totalisant **8 GPU**.

Toute cette puissance de calcul repose sur des unités **NVIDIA H100 80GB HBM3**, chacune présentant une consommation de pointe d'environ **700W**. Celles-ci sont hébergées dans une installation avec un **PUE (Power Usage Effectiveness) de 1,7**, ce qui signifie que pour chaque watt consommé par les GPU, 0,7 watt supplémentaire est nécessaire pour le refroidissement et la distribution d'énergie.

Les différents modèles d'IA utilisés se voient allouer **24 GPU H100**.

Nom du modèle	Configuration de déploiement	Matériel
Llama-3.3-70B	1 instance	4 GPU
Gpt-oss-120b	3 instances	6 GPU (2 par inst.)
Qwen3-VL-32B-Instruct	2 instances	4 GPU (2 par inst.)
Gpt-oss-20b	2 instances	2 GPU (1 par inst.)
Qwen2-1.5B-instruct	4 instances	4 GPU (1 par inst.)
Whisper-v3-Turbo	1 instance	1 GPU
gte-Qwen2-1.5B	1 instance	1 GPU

TABLE 1 – Distribution actuelle des modèles de la DGFIP et allocation des GPU

2.2 Empreinte environnementale des puces H100


Pour quantifier l'impact de la puissance de calcul, nous nous appuyons sur l'évaluation « Cradle-to-Gate » (de l'extraction des matériaux à la sortie d'usine) de l'architecture NVIDIA HGX H100 (80 Go HBM3).

Une unité est composée de 8 GPU. La répartition de l'empreinte carbone pour une unité est la suivante :

- **Composants (91%)** : Principalement tirés par la fabrication de la mémoire et des circuits intégrés (IC).
- **Assemblage et Transport (9%)** : Couvrant la construction finale et la logistique mondiale.

Selon ces spécifications, la base pour une carte HGX standard est de **1 312 kg CO₂e**. Pour la flotte actuelle de la DGFIP (24 GPU / 3 cartes), l'empreinte totale de fabrication atteint **3 936 kg CO₂e (3,9 t)**. À titre de comparaison, cela équivaut à **parcourir environ 18 000 km** dans une voiture thermique standard ou à la fabrication de 15 ordinateurs de bureau complets (hors écrans).

HGX H100 PCF: Material Breakdown by Component Type (Kg CO₂e/Unit)



Au-delà des métriques carbone, le processus de fabrication est extrêmement gourmand en ressources ; un seul GPU peut consommer plus de 30 000 litres d'eau pendant sa production (calculateur d'impact carbone ADEME).

Cependant, il est important de noter que lorsqu'elle est amortie sur une période d'utilisation standard de 4 ans, la phase de fabrication représente une part relativement faible des émissions totales du cycle de vie par rapport à la phase opérationnelle (SCHNEIDER et al. 2025).

2.3 Efficacité du centre de données

L'impact environnemental du matériel est amplifié par l'efficacité de l'environnement d'hébergement, mesurée par l'Indicateur d'Efficacité Énergétique (PUE).

Actuellement, le centre de données de la DGFIP fonctionne avec un PUE de 1,7, ce qui signifie que pour chaque 1 kWh consommé par les GPU, 0,7 kWh est perdu dans le support non informatique (principalement le refroidissement). Réduire cet indicateur vers une cible de 1,4 est une priorité pour abaisser la demande énergétique totale.

Pour garantir une vision holistique, notre cadre identifie également des sources d'émissions secondaires souvent omises :

- **Fuite de réfrigérant** : Les systèmes de refroidissement utilisent souvent des gaz tels que le R-134a, qui a un potentiel de réchauffement global (PRG) 1 430 fois supérieur au CO₂.
- **Alimentation de secours** : Les générateurs diesel émettent du CO₂ lors des tests mensuels obligatoires et des pannes de courant.

Recommandations stratégiques pour la DGFIP

- **Longévité du matériel** : Prolonger le cycle de vie des GPU actuels pour maximiser l'**amortissement** des émissions de fabrication.
- **Puces haute efficacité** : Privilégier les architectures à haut rendement lors du renouvellement (ex : les puces **NVIDIA B200**).
- **Refroidissement avancé** : Passer du refroidissement par air à des **systèmes de refroidissement par eau**. Cela peut réduire le PUE à $\sim 1,1$, diminuant l'empreinte opérationnelle d'environ 30%.
- **Infrastructure frugale (Récupération de chaleur)** : Réutiliser la **chaleur** générée par les serveurs pour chauffer les bâtiments à proximité.

Phase II : Entraînement initial

3.1 Cadre général pour comprendre la responsabilité de la DGFIP

Même si la DGFIP n'a pas entraîné ses propres modèles en interne, ceux-ci constituent des intrants en amont du cycle de vie de l'IA. En ce sens, ces modèles sont des ressources « pré-traitées » qui arrivent avec une dette carbone héritée de leur développement initial. Dans une ACV rigoureuse, il faut ne comptabiliser qu'une portion des émissions liées à l'entraînement, amortie sur le volume total d'inférence attendu pour chaque version.

Cependant, les méthodologies pour attribuer cette responsabilité fractionnaire restent sous-développées. Le principal obstacle est l'asymétrie des données : sans connaître le volume d'inférence total d'un modèle, un utilisateur unique ne peut mathématiquement déterminer sa part spécifique de la dette d'entraînement initiale. SCHWARTZ et al. 2019 soulignent le manque de normes de reporting et de transparence des créateurs de modèles, ce qui empêche les utilisateurs en aval de calculer leur dette carbone de manière précise.

Par conséquent, la popularité du modèle pourrait servir de substitut (proxy) pour le volume d'utilisation en aval : on considère que les modèles les plus populaires ont davantage d'utilisations en aval, et donc que la responsabilité fractionnaire des utilisateurs finaux est beaucoup plus faible. Cependant, cette logique crée une incitation perverse. Promouvoir des modèles populaires dits « efficaces » peut faire grimper la demande totale, conduisant finalement à l'entraînement de modèles successeurs encore plus grands et plus énergivores. Par exemple, GPT-3 était très populaire et a prouvé l'utilité des LLM. L'afflux massif d'utilisateurs a ensuite justifié la transition vers GPT-4, qui possède un nombre de paramètres dix fois supérieur (et donc une consommation énergétique accrue). C'est ce que LUCCIONI, VIGUIER et LIGOZAT 2022 appellent le paradoxe de Jevons, selon lequel l'amélioration de l'efficacité (ici, des émissions de carbone en amont plus faibles par utilisateur) peut paradoxalement stimuler une augmentation de la consommation. Par conséquent, nous ne pouvons pas simplement nous appuyer sur la popularité du modèle pour guider notre choix : un modèle plus populaire n'induit pas nécessairement une dette carbone moindre.

En conséquence, nous ne serons pas en mesure d'assigner des valeurs fermes de CO₂e pour l'entraînement initial qui auraient pu être proprement agrégées avec les émissions d'inférence de la DGFIP. Tout chiffre final unique pour les émissions de la plateforme serait statistiquement peu fiable et sujet à des marges d'erreur significatives.

Recommandation stratégique pour la DGFIP

Plutôt que de s'appuyer sur des attributions fractionnaires imprécises, nous proposons que la DGFIP évalue et sélectionne les modèles en fonction de leurs émissions absolues d'entraînement initial. En traitant la dette carbone totale héritée d'un modèle comme référence principale, la DGFIP peut s'assurer que ses critères de sélection sont directement proportionnels au coût environnemental de la création d'un modèle, même si sa part d'utilisation spécifique ne représente qu'une fraction de ce total.

3.2 Émissions de l'entraînement initial des modèles pré-entraînés utilisés par la DGFIP

Les modèles utilisés par la DGFIP proviennent de HuggingFace. Bien que HuggingFace encourage la transparence via sa fonctionnalité « Carbon Emissions » (*Displaying carbon emissions for your model* · Hugging Face 2026), cette dernière n'a pas encore fait l'objet d'une adoption

généralisée. Selon CASTAÑO et al. 2023, 99 % des modèles ne fournissent aucune information relative aux émissions, y compris des modèles fondateurs comme BERT ou GPT-2. Ce manque de données occulte l'impact environnemental et freine l'adoption de pratiques économes en carbone. Cependant, les auteurs proposent un schéma de classification en cinq catégories qui peut nous aider à comprendre les émissions d'entraînement initial des modèles utilisés par la DGFIP.

3.2.1 Efficacité énergétique certifiée

Cette catégorie exige des émissions optimisées et le respect de normes d'efficacité énergétique rigoureuses. Aucun des modèles utilisés par la DGFIP ou disponibles sur HuggingFace n'entre dans cette catégorie.

3.2.2 Sensibilisation à l'énergie (Energy awareness)

Cette catégorie désigne les modèles qui rapportent à la fois leurs émissions carbone et leur contexte technique (matériel, lieu d'entraînement, taille du jeu de données...). Le modèle Llama 3.3-70B utilisé par la DGFIP appartient à cette catégorie. En effet, sa « model card » sur HuggingFace *meta-llama/Meta-Llama-3-70B-Instruct · Hugging Face* 2024 indique des émissions d'entraînement de 11 390 tonnes de CO₂e pour l'ensemble de la collection et 2 040 tonnes de CO₂e pour ce modèle spécifique. Ils incluent également des informations contextuelles : le modèle a été entraîné pendant 39,3 millions d'heures-GPU sur des H100-80GB avec une enveloppe thermique (TDP) de 700W.

3.2.3 Reporting de base des émissions

Cette catégorie concerne les modèles qui fournissent un chiffre brut de CO₂e mais manquent de contexte pour rendre les données exploitables. Aucun des modèles de la DGFIP n'est dans cette catégorie.

3.2.4 Reporting du contexte

Cette catégorie désigne les modèles qui ne fournissent pas de chiffre d'émission final mais rapportent les variables techniques nécessaires pour l'estimer. Quatre des modèles utilisés par la DGFIP entrent dans cette catégorie. Pour ceux-ci, des outils comme *Machine Learning CO2 Impact Calculator* 2026 ou *Green Algorithms - Classic view* 2026 permettent d'obtenir des approximations approximatives des émissions d'entraînement.

Le modèle Qwen2.5-Coder-32B-Instruct (HUI et al. 2024) n'indique pas de temps d'entraînement mais rapporte un entraînement sur 5,5 billions (trillions) de jetons (KAPLAN et al. 2020). Le matériel utilisé est Alibaba Cloud (généralement des clusters H800 ou A800), avec un PUE de 1,2 (centres de données du nord de la Chine) et une intensité carbone de 550g/kWh (le réseau chinois dépendant du charbon). Ainsi, une estimation via ML CO₂ donne 466,4 tonnes de CO₂eq (*Alibaba Progresses Towards Carbon Neutrality Goals and Digital Inclusion* 2026).

La fiche du modèle gpt-oss120b (OPENAI et al. 2025) indique un total de 2,1 millions d'heures-H100 pour l'entraînement. Microsoft Azure (partenaire d'OpenAI) rapporte un PUE mondial pondéré de 1,12 pour ses nouveaux centres de données. L'intensité carbone aux États-Unis est d'environ 300g/kWh. Une estimation via ML CO₂ donne 1087 tonnes de CO₂eq. Le modèle gpt-oss20b a quant à lui nécessité 10 fois moins d'heures-H100, soit une estimation de 108,7 tonnes de CO₂eq.

Il s’agit toutefois d’approximations basées sur des lieux d’entraînement prédits ; elles ne doivent pas être prises au pied de la lettre en raison des incertitudes inhérentes aux mesures.

3.2.5 Émissions et contexte inconnus

C’est la catégorie dans laquelle tombent la plupart des modèles. L’absence de données occulte l’impact environnemental. Mistral rapporte 20 400 tonnes pour Large 2 (*Our contribution to a global environmental standard for AI* | Mistral AI 2026), mais aucune donnée spécifique pour Mistral-Small-24B-Instruct (*mistralai/Mistral-Small-24B-Instruct-2501* · Hugging Face 2026). Whisper-Large-v3 mentionne plus de 5 millions d’heures d’entraînement sans plus de détails (*openai/whisper-large-v3* · Hugging Face 2022). Qwen2-1.5B-Instruct évoque une « grande quantité de données » sans décompte précis (*Qwen/Qwen2-1.5B-Instruct* · Hugging Face 2026).

En l’absence de données, la DGFIP doit s’appuyer sur des indicateurs indirects (proxys) : lieu d’entraînement, type d’infrastructure, volume du jeu de données et taille du modèle.

a) Lieu d’entraînement La région géographique est l’un des facteurs les plus significatifs des émissions opérationnelles (DODGE et al. 2022). On peut se référer aux cartes de l’AIE (IEA) sur l’intensité carbone en temps réel (*Real-Time Electricity Tracker – Data Tools* 2026). Bien que souvent secrets, les lieux peuvent être déduits des rapports d’activité : GPT est principalement entraîné dans l’Iowa (West Des Moines) sur un supercalculateur dédié (BACH 2026). Llama utilise les hubs de l’Iowa et de l’Oregon (*Building Meta’s GenAI Infrastructure* 2024). Qwen s’appuie sur les régions de Zhangjiakou et Ulanqab en Chine (*Zhangjiakou Data Centers - 18 Facilities from Operators* 2026).

b) Types d’infrastructure Le PUE (Power Usage Effectiveness) mesure l’efficacité d’un centre de données. Alors que la moyenne mondiale est de 1,58, les installations d’IA modernes visent 1,10 à 1,15. Sans un PUE faible, la densité énergétique des architectures A100/H100 peut gonfler la consommation totale de 50 %. Pour la DGFIP, la transparence sur le PUE et l’architecture matérielle est essentielle pour quantifier la « dette carbone héritée ». En l’absence de données, la DGFIP doit supposer le pire scénario basé sur les moyennes mondiales.

c) Volume d’entraînement La dette carbone croît avec le nombre de jetons traités. L’inefficacité provient souvent de petites tailles de lots (batch sizes) qui ne saturent pas les GPU, laissant le matériel consommer de l’énergie quasi-maximale au repos (**patterson2021carbon**). La transparence est ici inégale : Llama et Qwen fournissent des données claires (15T et 5,5T jetons), contrairement à Mistral ou Whisper.

d) Taille du modèle Le nombre de paramètres est l’indicateur le plus constant et un prédicteur fiable du seuil minimal du coût environnemental de l’entraînement. Il existe une forte corrélation linéaire entre la taille et l’empreinte : un modèle dix fois plus grand générera généralement un impact d’un ordre de grandeur supérieur pour un même volume de jetons générés (*Our contribution to a global environmental standard for AI* | Mistral AI 2026). Pour la DGFIP, cela signifie que le nombre de paramètres permet un audit comparatif fiable des émissions incorporées au moment du déploiement.

TABLE 2 – Modèles pré-entraînés de la DGFIP : évaluation de l’entraînement initial

Nom du modèle	Taille (Paramètres)	Localisation (Intensité réseau)	Hardware & Infra (PUE)	Dataset (Frugalité)
GPT-OSS-120B	X (Très élevée)	~ (Réseau US)	~ (Azure - 1.12)	~ (MoE Standard)
GPT-OSS-20B	~ (Modérée)	~ (Réseau US)	~ (Azure - 1.12)	V (Efficace 4-bit)
Llama-3.3-70B	X (Élevée)	~ (US - Mixte)	~ (Meta - 1.15)	X (15T Tokens)
Qwen2.5-Coder-32B	~ (Modérée)	X (Élevée - Chine)	~ (Alibaba - 1.20)	~ (5.5T Tokens)
Mistral-Small-24B	~ (Modérée)	V (Basse - France)	~ (Cloud Standard)	? (Inconnu)
Whisper-v3-Turbo	V (Basse)	~ (Mixte/US)	? (Inconnu)	V (Couches élaguées)

3.3 Tableau des modèles de la DGFIP

Légende : V - indicateur favorable, ~ - modéré / données partielles ; X - indicateur défavorable ; ? - inconnu.

Recommandations stratégiques pour la DGFIP

L’entraînement et le développement peuvent représenter entre 50% et 65% de l’impact du cycle de vie pour les modèles en début de déploiement (LUCCIONI, VIGUIER et LIGOZAT 2022 ; MORRISON et al. 2025). Cette part peut descendre sous les 10% de l’énergie totale pour les modèles traitant de gros volumes de requêtes sur de longues périodes (BOSE 2025).

Par conséquent, bien que la DGFIP utilise des modèles pré-entraînés, la phase d’entraînement n’est pas négligeable car elle représente une dette carbone héritée qui caractérise la base de référence du modèle.

Pour en tenir compte, la DGFIP devrait prioriser les modèles disposant de données d’émissions rapportées de manière transparente. Lorsque ces données manquent (ce qui est souvent le cas), les indicateurs clés tels que la taille, l’emplacement et le matériel peuvent servir de substituts (proxys) fiables. Il est important de noter que l’objectif est de choisir un modèle avec de faibles émissions d’entraînement initial ; heureusement, les modèles à forte empreinte d’entraînement sont typiquement ceux ayant un nombre excessif de paramètres, ce qui entraîne également une consommation d’énergie plus élevée lors de l’inférence.

En privilégiant les modèles avec des “Model Cards” publiées et un reporting sur les émissions carbone ou le contexte technique, la DGFIP peut efficacement choisir des modèles pour atténuer sa dette carbone héritée tout en encourageant une plus grande transparence dans la chaîne d’approvisionnement de l’IA.

Phase II Bis : Fine-Tuning (Affinage)

Bien que la DGFIP n’affine actuellement aucun de ses modèles en interne, cela pourrait devenir pertinent à mesure que sa plateforme d’IA mûrit.

Il convient de noter que le fine-tuning est exponentiellement moins gourmand en calcul que le pré-entraînement. Pour un modèle de 7B paramètres utilisant des techniques efficaces comme LoRA, l’impact carbone peut être aussi bas que 50–100g CO₂e (soit l’équivalent de 250 à 400 mètres parcourus avec une voiture essence standard, ou l’énergie nécessaire pour faire bouillir quelques litres d’eau) (LUDVIGSEN 2024).

Si la DGFIP s’engageait dans le fine-tuning à l’avenir, le coût environnemental resterait négligeable par rapport à la dette d’entraînement héritée du modèle de base. L’impact varierait

toutefois considérablement selon la méthode d’affinage (LoRA vs affinage complet), l’architecture du modèle (dense vs creuse/sparse), le nombre d’époques et la taille du jeu de données d’entraînement.

Recommandation stratégique pour la DGFIP

Compte tenu du coût carbone négligeable par rapport au pré-entraînement, la phase de fine-tuning ne devrait pas être un facteur décisif dans la sélection d’un modèle. Cependant, l’adoption de méthodes efficaces reste une bonne pratique et assure la cohérence avec les objectifs globaux de réduction carbone de la DGFIP.

Phase III : Inférence

5.1 Développement de l’outil d’évaluation de l’inférence

En réponse aux demandes de la DGFIP, nous avons développé un outil d’évaluation dédié pour quantifier l’empreinte carbone de l’inférence des IA utilisées. L’objectif était de dépasser les estimations théoriques pour fournir une méthodologie basée sur les données issues des journaux (logs) réels de l’infrastructure.

L’outil suit un pipeline en trois étapes :

- **Entrées (Inputs)** : Nous collectons les données énergétiques via Dell iDRAC (`extract_iDRAC.py`) et les journaux d’activité du serveur (`parse_logs.py`) pour suivre le traitement des jetons (tokens).
- **Traitement (Processing)** : Les données sont agrégées à l’aide du modèle `Method_IAG.xlsx`, qui calcule la répartition de l’énergie entre les clusters de développement et de production.
- **Sortie (Output)** : Le système génère un rapport trimestriel suivant les indicateurs de performance clés (KPI), tels que le total des kWh, les émissions de CO_2e et l’efficacité globale.

5.2 Méthodologie et facteurs d’efficacité

L’empreinte carbone de l’inférence est calculée selon la formule suivante :

$$\text{Émissions de } CO_2 = \text{Consommation d'Énergie (W)} \times \text{PUE} \times \text{Mix Électrique} \quad (1)$$

Cependant, l’efficacité de l’inférence dépend fortement de la manière dont le modèle est optimisé et géré. Notre méthodologie applique quatre corrections critiques pour attribuer l’utilisation de l’énergie avec précision :

- **Quantification (Quantization)** : La précision du modèle influence considérablement les besoins de calcul. Par exemple, les modèles en FP8 utilisent environ 50% de calcul en moins que leurs équivalents en BF16.
- **Optimisation architecturale (MoE)** : Les modèles utilisant un mélange d’experts (Mixture of Experts - MoE), tels que *gptoss*, sont plus efficaces car ils n’activent qu’une petite fraction des paramètres par requête.
- **Optimisation de la taille des lots (Batch size)** : Pour garantir que chaque watt produit le maximum de jetons, nous visons à maximiser la taille des lots, en traitant plusieurs requêtes simultanément.
- **Base de consommation au repos (Idle power)** : Nous attribuons une part constante de 7% de la consommation totale d’énergie à la puissance “au repos” (GPU restant sous tension sans charge de travail active).

Bien que l’outil fournisse une base solide, plusieurs limites subsistent : la difficulté de suivre les temps exacts de déploiement/dé-déploiement par modèle, l’identification précise du GPU hébergeant chaque modèle dans un environnement partagé, et le manque actuel de données pour certaines périodes (ex. janvier 2026).

Recommandations stratégiques pour la DGFIP

Nous présentons dans la section "Méthodologie de l'outil" en détail une première version de l'outil qui permet d'extrapoler les résultats de consommation énergétique et d'émissions de GES dues à l'inférence sur toute la période où nous avons des données d'usage. Nous exposons ensuite les limites de cet outil, et proposons une version plus raffinée qui pourra être utilisée lorsque vous aurez les données nécessaires. Le détail de cette version est décrite dans le README. Le premier outil permet d'avoir une vue d'ensemble sur vos modèles, tandis que le deuxième permettra une compréhension raffinée de l'impact environnemental dû à l'inférence de la plateforme.

Phase IV : Gestion de la fin de vie

L'étape finale du cycle de vie de l'IA concerne le déclassement et l'élimination du matériel. Cette phase est de plus en plus critique car le rythme rapide de l'innovation conduit à des cycles matériels plus courts.

Il existe un manque important de mesures de déchets électroniques spécifiques à l'IA, ce qui rend difficile le suivi du volume exact et de la toxicité du matériel mis au rebut par le secteur (OECD 2022).

On observe également un paradoxe de l'obsolescence : les GPU haute performance font face à une fenêtre d'amortissement plus courte que les serveurs classiques. Alors qu'un serveur standard est généralement amorti sur 5 à 7 ans, les gains rapides d'efficacité du matériel d'IA (mesurés en *gCO₂e/Exaflop*) incitent au remplacement après seulement 3 ans (SCHWARTZ et al. 2019).

Le démantèlement et le transport de clusters d'IA spécialisés engendrent une empreinte logistique élevée. Actuellement, le recyclage en boucle fermée, où les matériaux des anciens GPU sont récupérés pour les nouveaux, a le potentiel de compenser environ 4% de l'empreinte carbone initiale de fabrication (SCHNEIDER et al. 2025).

Recommandations stratégiques pour la DGFiP

- **Extension de la durée de vie :** Viser l'extension de la durée de vie fonctionnelle des GPU actuels d'au moins une année supplémentaire. Cela réduit directement l'impact annuel de la dette de fabrication.
- **Collaborer avec vos fournisseurs de matériel,** Dell, pour établir et suivre des méthodologies de recyclage.
- **Suivi quantitatif :** Mettre en œuvre l'outil **NumEcoEval**, développé par le CGDD (Commissariat général au développement durable), pour quantifier précisément l'empreinte environnementale de chaque composant matériel et service numérique au sein de l'organisation **Lien vers le gitlab NumEcoEval.**

Méthodologie de l’outil

7.1 Aperçu et sources de données

L’outil d’attribution énergétique estime la consommation d’électricité et les émissions de CO₂ par modèle de langage (LLM) déployé par la DGFIP. L’outil combine deux catégories de données d’entrée :

- **Journaux d’utilisation** (passerelle API LiteLLM) : agrégats quotidiens par modèle du nombre de requêtes et des volumes de jetons (tokens), exportés sous forme de fichiers CSV. Deux fichiers sont utilisés : `diane_usage_daily_with_models_2026-01-28.csv` (oct.–déc. 2025, 163 lignes, 8 modèles) et `diane_usage_daily_with_models_fevrier.csv` (fév. 2026, 254 lignes, 9 modèles).
- **Données PDU (Power Distribution Unit)** : mesures électriques issues de l’instrumentation de la baie GPU. Pour décembre 2025, un instantané de 80 minutes (`Energy_Data_Clean.csv`, 89 lignes, 6 nœuds GPU) fournit la puissance active par nœud en Watts. Pour février 2026, le fichier `releves_AI_FEB_2026.csv` (28 991 lignes à intervalles de 5 minutes) fournit les compteurs d’énergie cumulative en Wh sur 6 circuits confirmés. Les données cumulatives indiquent des chocs (resets), entraînant une énergie négative par intervalle. Cela nous a conduits à déduire que les intervalles sont en réalité de 10 minutes avec deux voies énergétiques par circuit.

Les paramètres d’architecture des modèles (nombre total de paramètres, format de quantification, configuration Mixture-of-Experts) sont récupérés sur HuggingFace Hub via l’API de métadonnées safetensors, avec des valeurs de repli (fallback) codées en dur pour les dépôts privés.

7.2 Mesure de l’énergie

Février 2026 — mesure directe

Pour février 2026, l’énergie informatique (IT) totale est dérivée directement du compteur PDU cumulatif via les différences consécutives. Pour chaque circuit c et horodatage t :

Méthode du compteur cumulatif

$$\Delta W_{c,t} = \text{compteur}(c, t) - \text{compteur}(c, t - 1)$$

$$E_{IT} = \frac{1}{1000} \sum_c \sum_{\Delta W_{c,t} \geq 0} \Delta W_{c,t} \quad [\text{kWh}]$$

Les événements de réinitialisation ($\Delta W < 0$, correspondant au dépassement de capacité du compteur) sont écartés.

Résultat février 2026 : 253 réinitialisations filtrées ; $E_{IT} = \mathbf{5\,165}$ kWh (6 circuits confirmés).

Décembre 2025 — méthode puissance $\times$ temps de fonctionnement

L’instantané PDU de décembre ne couvre que 80 minutes (3 décembre 2025). Le temps de fonctionnement du cluster entre les dates d’observation étant inconnu, trois scénarios sont utilisés :

Scénarios énergétiques de décembre

$$E_{\text{IT,Dec}} = P_{\text{cluster}} \times 24 \times n_{\text{jours}} / 1000 \quad [\text{kWh}]$$

où $P_{\text{cluster}} = 8\,778 \text{ W}$ (somme des moyennes par nœud sur 6 nœuds A100).

Scénario	n_{jours}	$E_{\text{IT,Dec}}$ (kWh)
Optimiste (éteint si inactif)	54	11 376
Central (moyenne)	72	15 274
Pessimiste (24/7)	91	19 171

Énergie de l'installation et CO₂

L'énergie de l'installation prend en compte les frais généraux du centre de données (refroidissement, conversion de puissance, réseau) via le ratio d'efficacité énergétique (PUE) :

Énergie de l'installation et empreinte carbone

$$E_{\text{installation}} = E_{\text{IT}} \times \underbrace{1.7}_{\text{PUE}} \quad \text{CO}_2 = E_{\text{installation}} \times \underbrace{0.052}_{\text{kg CO}_2\text{e/kWh}}$$

Le facteur d'intensité CO₂ de 0,052 kg CO₂e/kWh correspond à la moyenne annuelle du réseau national français pour 2024 (RTE éco2mix).

7.3 Attribution par modèle

L'énergie totale du cluster ne peut être mesurée directement par modèle. L'outil attribue l'énergie de l'installation à chaque modèle proportionnellement à un **poids computationnel** w_i servant de proxy pour les FLOPs générés par chaque modèle. Trois corrections sont appliquées par rapport à une attribution naïve basée uniquement sur les jetons.

Correction 1 — Précision numérique

Les modèles quantifiés effectuent moins d'opérations en virgule flottante par jeton. Le facteur de quantification q_i est défini par rapport au format FP16 :

Correction 1 : facteur de quantification q_i

$$w_i^{(1)} = \text{jetons}_i \times \text{paramtres}_i \times q_i$$

Format	q_i	Dérivation	Modèles
BF16 / FP16	1.000	Référence	Llama-3.3-70B, qwen3vl, Whisper, gte
FP8	0.500	8/16	Qwen-Coder-32B, Mistral- Small-24B
MXFP4-MoE	0.339	$0.10 \times 1 + 0.90 \times$ (4.25/16)	gptoss120b, gptoss20b

Le facteur MXFP4 tient compte d'une mantisse de 4 bits avec un exposant partagé (soit 4,25 bits effectifs) appliquée à 90% des poids, les 10% restants étant conservés en FP16.

Correction 2 — Paramètres actifs Mixture-of-Experts

Les modèles Mixture-of-Experts (MoE) contiennent N sous-réseaux spécialisés (experts) mais n'en activent que K par jeton lors de l'inférence. Le nombre de paramètres effectifs par jeton est donc bien inférieur au total :

Correction 2 : paramètres effectifs MoE

$$\text{param_eff}_i = (1 - f_{\text{MoE}}) \cdot \text{params}_i + \frac{K}{N} \cdot f_{\text{MoE}} \cdot \text{params}_i$$

où $f_{\text{MoE}} = 0.90$ (fraction de paramètres dans les couches MoE).

Modèle	N experts	Top- K	Params totaux	Params effectifs
gptoss120b	128	4	120,4 B	15,4 B (−87%)
gptoss20b	32	4	21,5 B	4,6 B (−79%)

Correction 3 — Puissance au repos des GPU (Idle power)

Les GPU NVIDIA A100 sont verrouillés dans l'état P0 (fréquence d'horloge maximale) tant qu'un contexte CUDA est actif et ne peuvent pas passer à des états de puissance inférieure. Cela entraîne une consommation persistante au repos d'environ 50 W par GPU, quel que soit l'état de l'inférence (confirmé à 62 W par nvidia-smi à 0% d'utilisation). Cette consommation doit être allouée par *temps d'hébergement* et non par volume de jetons.

Correction 3 : allocation de la puissance au repos

$$s_i = \underbrace{(1 - \gamma)}_{93\%} \cdot \frac{w_i}{\sum_j w_j} + \underbrace{\gamma}_{7\%} \cdot \frac{d_i}{\sum_j d_j}$$

où $\gamma = 0,07$ (fraction au repos, conservatrice par rapport aux 12–21% rapportés dans la littérature), $w_i = \text{jetons}_i \times \text{param_eff}_i \times q_i$ est le poids computationnel corrigé, et d_i est le nombre de jours pendant lesquels le modèle i a été chargé en mémoire GPU.

7.4 Énergie finale et CO₂ par modèle

Résultat de l'attribution

$$E_i = s_i \times E_{\text{installation}} \quad \text{CO}_{2,i} = E_i \times 0.052$$

Métriques d'efficacité dérivées :

$$\text{kWh/Mjetons}_i = \frac{E_i}{\text{jetons}_i/10^6} \quad \text{Wh/req}_i = \frac{E_i \times 1000}{\text{reques}_i} \quad \text{gCO}_2/\text{req}_i = \text{Wh/req}_i \times 0.052$$

7.5 Résultats de février 2026

Modèle	Part	kWh	CO ₂ (kg)	kWh/Mjet	Wh/req	gCO ₂ /req
Llama-3.3-70B-128k	60%	5 233	272	16,91	4,82	0,251
qwen3vl32binstruct	28%	2 447	127	7,91	2,25	0,117
gptoss120b	6%	484	25	1,57	0,45	0,023
gte-Qwen2-1.5B-instruct	3%	240	13	0,78	0,21	0,011
gptoss20b	2%	214	11	0,69	0,20	0,010
deepdml-Whisper-v3-turbo	2%	160	8	0,52	0,15	0,008
Total	100%	8 780	457	4,73	1,34	0,070

TABLE 3 – Attribution de l'énergie et du CO₂ par modèle, février 2026 (1–24 fév.). Énergie installation, PUE = 1.7, CO₂ = 0.052 kg/kWh. Trois modèles n'ont eu aucune utilisation en février (Mistral, Qwen-Coder, dgfip-e5).

7.6 Limites et incertitudes connues

- **Pas de distinction jetons entrée/sortie** : les jetons de sortie coûtent environ 2× plus de FLOPs que les jetons d'entrée. Sans cette distinction, l'attribution est systématiquement biaisée pour les modèles ayant des ratios de génération différents.
- **Instantané de décembre limité à 80 minutes** : la référence de puissance de décembre ($P_{\text{cluster}} = 8\,778\text{ W}$) peut ne pas être représentative de la charge de travail complète d'octobre à décembre, entraînant une plage de variation de $\pm 34\%$ dans les estimations de cette période selon les scénarios de temps de fonctionnement.

Recommandations stratégiques pour la DGFIP

Afin de faire évoluer le proof-of-concept de suivi énergétique vers un système opérationnel, nous recommandons les améliorations techniques suivantes :

- **Transition vers un suivi au niveau du GPU :** Remplacer les données énergétiques globales des PDU par un relevé granulaire de la consommation par GPU via l'interface `nvidia-smi`. Cette étape est indispensable pour ventiler précisément la consommation lorsque plusieurs modèles partagent la même infrastructure.
 - **Amélioration de la granularité des données :** Mettre à jour le pipeline d'exportation pour fournir des données sur les jetons (tokens) et les requêtes par modèle à des intervalles de 5 minutes. Cela permettra d'identifier les périodes d'inactivité des serveurs et de soustraire la « puissance au repos » (idle power), qui surestime actuellement les émissions actives d'environ 10%.
 - **Différenciation de l'impact des jetons :** Modifier l'outil d'évaluation pour distinguer les jetons d'entrée (prompt) des jetons de sortie (génération). Les jetons de sortie étant nettement plus gourmands en calcul, cette distinction est nécessaire pour obtenir une empreinte carbone précise par requête.
 - **Automatisation du contexte environnemental :** Intégrer l'outil aux archives historiques de l'intensité carbone de RTE pour garantir un reporting précis sur les périodes de plus de 6 semaines. Maintenir également une correspondance synchronisée entre les modèles internes et les métadonnées Hugging Face pour automatiser la récupération des paramètres et de la quantification.
- => Se référer au README pour les détails de l'outil adapté.

Conclusion

8.1 Conclusion sur l'ensemble de l'ACV

Cette évaluation a permis d'obtenir une vision globale de l'impact environnemental des activités d'IA au sein de la DGFIP. En dépassant les simples métriques énergétiques pour adopter une Analyse du Cycle de Vie (ACV) multicritère, nous avons identifié des leviers d'action pour aligner le développement de l'IA à la DGFIP avec les objectifs de durabilité.

Notre analyse du cycle de vie de l'IA met en évidence quatre domaines d'intervention prioritaires :

Matériel et infrastructure : Des impacts significatifs sont incorporés dès la phase de fabrication. Prolonger la durée de vie de vos GPU et améliorer l'efficacité des centres de données grâce à un PUE optimisé et un refroidissement avancé restent les stratégies les plus efficaces pour réduire cette charge.

Entraînement initial des modèles : Les futurs achats devraient prioriser les modèles disposant d'un reporting environnemental transparent, en examinant spécifiquement des indicateurs tels que la taille du modèle, le lieu d'entraînement (intensité carbone du réseau) et l'efficacité du matériel utilisé.

Phase d'inférence : Comme il s'agit de la phase la plus énergivore sur le long terme, il est nécessaire de déployer une surveillance au niveau du GPU et d'utiliser les outils d'évaluation que nous avons développés pour affiner les estimations d'émissions et comparer l'efficacité des modèles en temps réel.

Fin de vie : L'intégration de stratégies de recyclage et la planification d'un amortissement à long terme du matériel sont essentielles pour atténuer le paradoxe de l'obsolescence induit par les gains technologiques rapides.

8.2 Recommandations finales et extensions

Pour appuyer les futures prises de décision, nous recommandons l'utilisation des initiatives et outils open-source suivants :

- **Ecologits Carbon Tracker** : Un outil open-source conçu pour estimer la consommation d'énergie et l'empreinte environnementale des modèles d'IA générative. **Calculateur Ecologits**
- **AI Energy Score** : Une initiative fournissant des évaluations comparatives de l'efficacité énergétique des modèles d'IA. Puisqu'ils utilisent les mêmes GPU H100 que la DGFIP, leurs classements sont idéaux pour benchmarker vos modèles internes. **Classement AI Energy Score**

L'ensemble des documents associés à ce projet a été centralisé dans un répertoire GitHub dédié.

Bibliographie

- Alibaba Progresses Towards Carbon Neutrality Goals and Digital Inclusion* (2026). *Alibaba Progresses Towards Carbon Neutrality Goals and Digital Inclusion : 2024 ESG Report-Alibaba Group*. URL : <https://www.alibabagroup.com/en-US/document-1752073403914780672> (visité le 23/02/2026).
- BACH, Deborah (2026). *How a small city in Iowa became an epicenter for advancing AI*. en-US. URL : <https://news.microsoft.com/source/features/ai/west-des-moines-iowa-ai-supercomputer/> (visité le 14/03/2026).
- BERTHELOT, Adrien et al. (jan. 2024). « Estimating the environmental impact of Generative-AI services using an LCA-based methodology ». In : *Procedia CIRP*. 31st CIRP Conference on Life Cycle Engineering 122, p. 707-712. ISSN : 2212-8271. DOI : 10.1016/j.procir.2024.01.098. URL : <https://www.sciencedirect.com/science/article/pii/S2212827124001173> (visité le 01/12/2025).
- BOSE, Pinaki (nov. 2025). « From Red AI to Green AI : A Unified Survey of Lifecycle Costs, Efficiency Techniques, and a Comprehensive Reporting Framework ». en. In : *The American Journal of Engineering and Technology* 7.11, p. 204-212. ISSN : 2689-0984. DOI : 10.37547/tajet/v7i11-310. URL : <https://theamericanjournals.com/> (visité le 15/03/2026).
- Building Meta's GenAI Infrastructure* (mars 2024). en-US. URL : <https://engineering.fb.com/2024/03/12/data-center-engineering/building-metas-genai-infrastructure/> (visité le 14/03/2026).
- CASTAÑO, Joel et al. (oct. 2023). « Exploring the Carbon Footprint of Hugging Face's ML Models : A Repository Mining Study ». In : *2023 ACM/IEEE International Symposium on Empirical Software Engineering and Measurement (ESEM)*, p. 1-12. DOI : 10.1109/ESEM56168.2023.10304801. URL : <https://ieeexplore.ieee.org/abstract/document/10304801> (visité le 17/02/2026).
- CIAMBRONE, David F. (fév. 2018). *Environmental Life Cycle Analysis*. Boca Raton : CRC Press. ISBN : 978-0-203-75703-1. DOI : 10.1201/9780203757031.
- Displaying carbon emissions for your model · Hugging Face* (2026). URL : <https://huggingface.co/docs/hub/en/model-cards-co2> (visité le 14/03/2026).
- DODGE, Jesse et al. (juin 2022). « Measuring the Carbon Intensity of AI in Cloud Instances ». In : *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency*. FAccT '22. New York, NY, USA : Association for Computing Machinery, p. 1877-1894. ISBN : 978-1-4503-9352-2. DOI : 10.1145/3531146.3533234. URL : <https://dl.acm.org/doi/10.1145/3531146.3533234> (visité le 24/02/2026).
- Green Algorithms - Classic view* (2026). URL : <https://calculator.green-algorithms.org/> (visité le 14/03/2026).
- HUI, Binyuan et al. (nov. 2024). *Qwen2.5-Coder Technical Report*. arXiv :2409.12186 [cs]. DOI : 10.48550/arXiv.2409.12186. URL : <http://arxiv.org/abs/2409.12186> (visité le 23/02/2026).
- KAPLAN, Jared et al. (jan. 2020). *Scaling Laws for Neural Language Models*. arXiv :2001.08361 [cs]. DOI : 10.48550/arXiv.2001.08361. URL : <http://arxiv.org/abs/2001.08361> (visité le 24/02/2026).
- LUCCIONI, Alexandra Sasha, Sylvain VIGUIER et Anne-Laure LIGOZAT (nov. 2022). *Estimating the Carbon Footprint of BLOOM, a 176B Parameter Language Model*. arXiv :2211.02001 [cs]. DOI : 10.48550/arXiv.2211.02001. URL : <http://arxiv.org/abs/2211.02001> (visité le 01/12/2025).
- (2023). « Estimating the Carbon Footprint of BLOOM, a 176B Parameter Language Model ». In : *Journal of Machine Learning Research* 24.253, p. 1-15. ISSN : 1533-7928. URL : <http://jmlr.org/papers/v24/23-0069.html> (visité le 11/01/2026).

- LUDVIGSEN, Kasper Groes Albin (fév. 2024). *Carbon footprint of LLM fine tuning — a case study*. en. URL : <https://medium.com/data-science/carbon-footprint-of-llm-fine-tuning-a-case-study-7703afc716a9> (visité le 11/01/2026).
- Machine Learning CO2 Impact Calculator* (2026). en. URL : <https://mlco2.github.io/impact> (visité le 15/03/2026).
- meta-llama/Meta-Llama-3-70B-Instruct* · Hugging Face (déc. 2024). URL : <https://huggingface.co/meta-llama/Meta-Llama-3-70B-Instruct> (visité le 14/03/2026).
- mistralai/Mistral-Small-24B-Instruct-2501* · Hugging Face (2026). URL : <https://huggingface.co/mistralai/Mistral-Small-24B-Instruct-2501> (visité le 14/03/2026).
- MORRISON, Jacob et al. (mars 2025). *Holistically Evaluating the Environmental Impact of Creating Language Models*. arXiv :2503.05804 [cs]. DOI : 10.48550/arXiv.2503.05804. URL : <http://arxiv.org/abs/2503.05804> (visité le 15/03/2026).
- OECD (nov. 2022). « Measuring the environmental impacts of artificial intelligence compute and applications : The AI footprint ». en. In : *OECD Digital Economy Papers*. DOI : 10.1787/7babf571-en. URL : https://www.oecd.org/en/publications/measuring-the-environmental-impacts-of-artificial-intelligence-compute-and-applications_7babf571-en.html (visité le 19/03/2026).
- OPENAI et al. (août 2025). *gpt-oss-120b & gpt-oss-20b Model Card*. arXiv :2508.10925 [cs]. DOI : 10.48550/arXiv.2508.10925. URL : <http://arxiv.org/abs/2508.10925> (visité le 23/02/2026).
- openai/whisper-large-v3* · Hugging Face (déc. 2022). URL : <https://huggingface.co/openai/whisper-large-v3> (visité le 14/03/2026).
- Our contribution to a global environmental standard for AI | Mistral AI* (2026). en. URL : <https://mistral.ai/news/our-contribution-to-a-global-environmental-standard-for-ai> (visité le 11/01/2026).
- PLOCIENNIK, Christiane et al. (jan. 2025). « Life Cycle Assessment of Artificial Intelligence Applications : Research Gaps and Opportunities ». In : *Procedia CIRP*. 32nd CIRP Conference on Life Cycle Engineering (LCE2025) 135, p. 924-929. ISSN : 2212-8271. DOI : 10.1016/j.procir.2025.01.079. URL : <https://www.sciencedirect.com/science/article/pii/S2212827125003749> (visité le 11/01/2026).
- Qwen/Qwen2-1.5B-Instruct* · Hugging Face (mars 2026). URL : <https://huggingface.co/Qwen/Qwen2-1.5B-Instruct> (visité le 14/03/2026).
- Real-Time Electricity Tracker – Data Tools* (2026). en-GB. URL : <https://www.iea.org/data-and-statistics/data-tools/real-time-electricity-tracker> (visité le 14/03/2026).
- SCHNEIDER, Ian et al. (fév. 2025). *Life-Cycle Emissions of AI Hardware : A Cradle-To-Grave Approach and Generational Trends*. arXiv :2502.01671 [cs]. DOI : 10.48550/arXiv.2502.01671. URL : <http://arxiv.org/abs/2502.01671> (visité le 23/02/2026).
- SCHWARTZ, Roy et al. (août 2019). *Green AI*. arXiv :1907.10597 [cs]. DOI : 10.48550/arXiv.1907.10597. URL : <http://arxiv.org/abs/1907.10597> (visité le 23/02/2026).
- Zhangjiakou Data Centers - 18 Facilities from Operators* (2026). en. URL : <https://www.datacentermap.com/china/zhangjiakou/> (visité le 14/03/2026).